

LECTURE NOTE

神经网络：表达、记忆与优化

L15-L16 幻灯片与两本机器学习理论教材的整合讲义

核心主线 神经网络同时是一种可学习特征映射、函数逼近器和可优化的复合模型。理解它需要把表达能力、有限样本记忆、优化动力学与泛化控制放到同一张图里。

课程：CIT413048 Mathematical Foundations of ML

基于 Suvrit Sra 的 L15 / L16 (2026-06-09)

补充：Francis Bach, Learning Theory from First Principles;
Shalev-Shwartz & Ben-David, Understanding Machine Learning

阅读导航

这份讲义不是逐页复述，而是围绕“模型是什么—能表示什么—如何训练—为何可能泛化”重排材料。公式采用统一的列向量约定，避免原幻灯片与教材之间转置方向不一致。

模块	要回答的问题	主要材料
A. 表示	网络如何从固定特征走向可学习特征？	L15 pp. 2–25; Bach §9.1–9.2
B. 表达能力	万能逼近说明了什么，又没有说明什么？	L15 pp. 26–40; Bach §9.3–9.5; UML §20.3–20.4
C. 记忆	有限样本插值与 VC 维有什么区别？	L16 pp. 3–14
D. 优化	SGD 与反向传播如何得到梯度？	L16 pp. 15–36; Bach §5.4; UML §20.6
E. 稳定与正则化	初始化、Dropout、BN 如何影响训练？	L16 pp. 20–47
F. 泛化	参数多为何不必然意味着泛化差？	Bach §9.2.3–9.4; UML §20.4

符号约定

符号	含义
$\mathbf{x} \in \mathbb{R}^d, \mathbf{y}$	输入与标签
L	不计输入层的网络深度
$\mathbf{W}^l \in \mathbb{R}^{m_l \times m_{l-1}}, \mathbf{b}^l \in \mathbb{R}^{m_l}$	第 l 层权重与偏置
$\mathbf{z}^l, \mathbf{a}^l$	预激活与激活, $\mathbf{a}^0 = \mathbf{x}$
σ	逐坐标激活函数; $\text{ReLU}(u) = \max\{u, 0\}$

符号	含义
θ	所有权重和偏置的集合
$R(\theta), R_n(\theta)$	总体风险与经验风险

1. 从固定特征到可学习特征

1.1 核方法视角

核方法先选定核 k ，再由训练数据产生隐式特征。以核 SVM 为例，表示定理给出 $w = \sum_i \alpha_i y_i \varphi(x_i)$ ，预测为：

$$\langle w, \varphi(x) \rangle = \sum_i \alpha_i y_i k(x_i, x) = \langle \alpha, \Phi(x) \rangle, \quad \Phi(x) = [y_1 k(x_1, x), \dots, y_n k(x_n, x)]^T.$$

因此分类器对 $\Phi(x)$ 是线性的，但 Φ 的形状由核预先固定。神经网络的关键变化是：把特征本身参数化，并与最后的线性分类器联合学习。

$$x \mapsto \Phi_{\{\theta_1\}}(x) \mapsto w^T \Phi_{\{\theta_1\}}(x) + b, \quad \theta = (\theta_1, w, b).$$

四种等价直觉 神经网络可被看成：①可学习特征；②嵌套分类器；③由简单决策逐层组成复杂决策；④可组合的函数逼近器。

来源：L15 pp. 5–13; Bach, Ch. 9, pp. 247–250.

1.2 前馈网络的统一写法

令 $a^0 = x$ 。对 $l = 1, \dots, L$ ，定义

$$z^l = W^l a^{l-1} + b^l, \quad a^l = \sigma^l(z^l). \quad (1.1)$$

若最后一层为线性输出，则 $F(x; \theta) = z^L$ ；若是分类问题，常把 z^L 解释为 logits，再配合 sigmoid 或 softmax 与交叉熵。输入层只存储数据，不计入深度。

$$F(x; \theta) = W^L \sigma^{\{L-1\}}(W^{\{L-1\}} \cdots \sigma^1(W^1 x + b^1) \cdots + b^{\{L-1\}}) + b^L.$$

1.3 一层与单隐层网络

没有隐藏层时，网络退化为线性模型 $z = w^T x + b$ ；加上 sign 得到线性分类器，加上 sigmoid 与对数损失得到逻辑回归。单隐层标量输出网络为

$$f(x) = \sum_{j=1}^m \eta_j \sigma(w_j^T x + b_j). \quad (1.2)$$

固定 (w_j, b_j) 时，这是在 m 个固定特征 $\sigma(w_j^T x + b_j)$ 上的线性模型；同时优化输入权重时，模型开始“学习特征”。

来源：L15 pp. 14–18; Bach §9.2; UML §20.1。

2. 激活函数、输出层与损失

函数	定义	导数/性质	典型作用
Sigmoid	$\sigma(u) = 1/(1 + e^{-u})$	$\sigma' = \sigma(1 - \sigma)$, 大 $ u $ 饱和	二分类概率输出
tanh	$\tanh(u)$	$1 - \tanh^2(u)$, 零中心但会饱和	传统隐藏层
ReLU	$[u]_+ = \max(0, u)$	$1\{u > 0\}$ ($u=0$ 取次梯度)	现代隐藏层基础
Softmax	$p_k = e^{z_k} / \sum_j e^{z_j}$	$J = \text{diag}(p) - pp^T$	多分类概率输出

2.1 交叉熵与逻辑损失的等价性

对二分类 $y \in \{-1, +1\}$ ，令 $g(x) = \text{sigmoid}(f(x))$ 。负对数似然为

$$-1\{y=1\} \log g(x) - 1\{y=-1\} \log(1 - g(x)) = \log(1 + e^{-yf(x)}). \quad (2.1)$$

所以“sigmoid + binary cross-entropy”与直接对 logit 使用 logistic loss 完全等价。数值实现通常直接从 logits 计算，以避免先取概率产生上溢或下溢。

2.2 Softmax 交叉熵梯度

若真实类别的 one-hot 向量为 y ， $p = \text{softmax}(z)$ ，损失 $\ell = -\sum_k y_k \log p_k$ ，则

$$\partial \ell / \partial z = p - y. \quad (2.2)$$

推导: $\partial \log p_r / \partial z_k = \delta_{rk} - p_k$, 因此 $\partial \ell / \partial z_k = -\sum_r y_r (\delta_{rk} - p_k) = p_k - y_k$ 。这个简洁结果是多分类反向传播的起点。

3. 非线性特征如何产生线性可分性

两个 ReLU 单元定义两个半空间响应:

$$z_1 = w_1^T x + b_1, \quad z_2 = w_2^T x + b_2, \quad \Phi(x) = ([z_1]_+, [z_2]_+).$$

原空间中非线性可分的数据, 在 $\Phi(x)$ 空间中可能被一条直线分开。每个 ReLU 把一个仿射超平面一侧截为零, 另一侧保留线性距离信息; 多个单元共同把输入空间切成多面体区域, 并在每个区域上实现不同的仿射映射。

重要限制 表示存在性不等于训练可达性。即使某组超平面能把样本变得线性可分, 梯度法仍需从随机初始化中找到合适方向; 法向量符号翻转就可能产生完全不同的特征。

来源: L15 pp. 19-25.

4. 表达能力与万能逼近

4.1 万能逼近定理的准确含义

经典结果表明: 在紧集上, 只要激活函数满足适当条件, 单隐层网络可以把任意连续函数逼近到任意精度。对 ReLU, 非多项式性足以推出稠密性。形式化地, 对紧集 $K \subset \mathbb{R}^d$ 、连续 g 与任意 $\varepsilon > 0$, 存在 m 与参数使

$$\sup_{x \in K} |\sum_{j=1}^m \eta_j \sigma(w_j^T x + b_j) - g(x)| < \varepsilon. \quad (4.1)$$

万能逼近没有保证的三件事 它不保证所需宽度小、不保证训练算法能找到参数, 也不保证从有限数据学到的函数具有小测试误差。表达、优化与泛化必须分开讨论。

4.2 一维 ReLU 表示的直接推导

设 f 在 $[-R, R]$ 上连续分段仿射, 折点 $a_1 < \dots < a_k$, 各区间斜率为 $v_0, \dots, v_k$ 。ReLU 的导数是阶跃函数, 所以每增加一个 ReLU 就能在一个折点改变斜率。由此得到精确表示

$$f(x) = f(-R) + v_0(x+R) + \sum_{j=1}^k (v_j - v_{j-1})(x - a_j)_+. \quad (4.2)$$

验证很直接：在 $x < a_1$ 时导数为 v_0 ；越过 a_j 后，导数增加 $v_j - v_{j-1}$ ，于是新斜率变为 v_j 。连续函数可被细网格上的分段线性插值一致逼近，因此得到一维万能逼近。

4.3 光滑函数的积分表示

若 f 二次连续可微，Taylor 公式的积分余项给出

$$f(x) = f(-R) + f'(-R)(x+R) + \int_{-R}^x f''(b)(x-b)_+ db. \quad (4.3)$$

这说明 ReLU 不只是离散折线基：连续的 ReLU 混合可以精确重建光滑函数。输出权重总变差由 $\int |f''(b)| db$ 控制，为后面的范数型泛化界提供桥梁。

来源：Bach §9.3.1–9.3.3, pp. 256–263。

4.4 多维证明框架与三层构造

1. 利用连续性：把 $[0,1]^d$ 划分为足够小的超矩形，在每个小块内用常数近似 g 。
2. 把分段常数写成超矩形指示函数的线性组合。
3. 用两层 ReLU 构造连续“软指示器”，在边界薄层外逼近每个超矩形指示函数。
4. 最后用线性输出层叠加这些软指示器，从而逼近 g 。

该思路解释了 L15 中“三层 ReLU 网络万能逼近”的直接证明。注意幻灯片把积分 L^1 误差写作 $\|\cdot\|_\infty$ 的位置应区分：一致误差是 $\sup$ 范数，积分绝对误差是 L^1 范数。

来源：L15 pp. 28–30; UML Ch. 20, Exercise 1。

4.5 深度为何可能节省宽度

万能逼近只说“能表示”，而深度分离关注“表示得是否高效”。L15 给出的典型例子是单位球指示函数：三层网络先近似每个坐标平方，再求和得到 $\|x\|^2$ ，最后近似阈值；宽度对 d 与 $1/\varepsilon$ 为多项式。某些两层网络若要达到固定高精度，则需要指数级宽度。

$$x \mapsto (x_1^2, \dots, x_d^2) \mapsto \sum_i x_i^2 = \|x\|_2^2 \mapsto 1_{\{\|x\|_2 \leq 1\}}.$$

本质是复用中间计算。深层网络把可组合结构 $f \circ g \circ h$ 显式编码；浅层网络可能只能用大量基函数“平铺”同一结构。深度并非总有优势，优势依赖目标函数与架构之间是否存在匹配的组合结构。

来源：L15 pp. 31–39; Safran & Shamir (2017) 摘要性结果。

5. 近似、估计与优化：三种误差

经验风险最小化的分析应把三种问题分开：函数类是否足够丰富（近似误差）、样本是否足够（估计误差）、算法是否找到足够好的经验解（优化误差）。

$$R(\hat{f}) - \inf_f R(f) = \text{approximation} + \text{estimation} + \text{optimization} \quad (\text{概念分解}).$$

更具体地，令 $\mathcal{F}$ 为模型类、 f^* 为总体最优函数、 $f^*_{\mathcal{F}} = \arg\min_{f \in \mathcal{F}} R(f)$ ， $\hat{f}$ 为算法输出，则可写成

$$R(\hat{f}) - R(f^*) = [R(f^*_{\mathcal{F}}) - R(f^*)] + [R(\hat{f}_{\text{ERM}}) - R(f^*_{\mathcal{F}})] + [R(\hat{f}) - R(\hat{f}_{\text{ERM}})].$$

实际界会通过经验风险与总体风险的偏差来控制第二项。这个框架能澄清一个常见误区：训练误差为零只意味着优化/插值成功，不能单独推出总体风险小。

5.1 ReLU 网络的范数与 Rademacher 界

对单隐层 ReLU 网络 $f(x) = \sum_i \eta_i(w_i^T x + b_i)_+$ ，假设 $\|x\|_2 \leq R$ ，归一化 $\|w_i\|_2^2 + b_i^2/R^2 = 1$ ，并约束 $\|\eta\|_1 \leq D$ 。若损失对预测是 G -Lipschitz，则经验风险最小化的期望估计误差满足

$$E[R(\hat{f}) - \inf_{f \in \mathcal{F}} R(f)] \leq 16GDR/\sqrt{n}. \quad (5.1)$$

推导主链如下。先由收缩不等式去掉损失，再用 ℓ_1/ℓ_∞ 对偶把对所有神经元的优化化为对单个神经元的上确界，再用 ReLU 的 1-Lipschitz 性与 Cauchy–Schwarz：

$$\begin{aligned} \mathcal{R}_n(\ell \circ \mathcal{F}) &\leq 2GD \cdot E \sup_{\{\|w\|^2 + b^2/R^2 = 1\}} |(1/n) \sum_i \epsilon_i (w^T x_i + b)| \\ &\leq 2GD \cdot E[(\|(1/n) \sum_i \epsilon_i x_i\|^2 + R^2 ((1/n) \sum_i \epsilon_i)^2)^{1/2}] \leq 4GDR/\sqrt{n}. \end{aligned}$$

关键结论是：在这个界里，隐藏单元数 m 没有显式出现；真正控制估计误差的是权重范数。参数数量并非完全无关，但“参数多 $\Rightarrow$ 必然泛化差”不是正确推理。

来源：Bach §9.2.3, Proposition 9.1.

5.2 ReLU 正齐次性与隐含 ℓ_1 正则

ReLU 满足 $(\alpha u)_+ = \alpha(u)_+$ ($\alpha > 0$)。因此单个神经元 $\eta(w^T x + b)_+$ 在缩放 $\eta \rightarrow \alpha\eta$ 、 $(w, b) \rightarrow (w, b)/\alpha$ 后保持不变。若使用平方 ℓ_2 权重衰减，单元的惩罚可写为

$$\alpha^2 \eta^2 + (\|w\|^2 + b^2/R^2)/\alpha^2.$$

对 α 优化。令 $c^2 = \|w\|^2 + b^2/R^2$ ，由 AM–GM 或求导可得 $\alpha^2 = c/|\eta|$ ，最小值为

$$\min_{\{\alpha > 0\}} [\alpha^2 \eta^2 + c^2/\alpha^2] = 2|\eta|c. \quad (5.2)$$

在 $c=1$ 的归一化下，这就是输出权重的 ℓ_1 惩罚，解释了正齐次网络中平方权重衰减与稀疏/变差范数之间的联系。

来源: Bach §9.2.2.

6. 有限样本表达能力与记忆

6.1 定义与 VC 维的区别

给定 N 个互异输入 $x_i \in \mathbb{R}^d$ 和任意目标 $y_i \in \mathbb{R}^p$, 若存在 θ 使 $f_\theta(x_i) = y_i$ 对所有 i 成立, 则称网络对该数据集可插值。若对任意这样的数据集都成立, 则称具有 N 点的普适有限样本表达能力。

$$\text{MemCap}(\mathcal{F}) = \max\{N: \forall \{(x_i, y_i)\}_{i=1}^N, \exists \theta, f_\theta(x_i) = y_i\}.$$

概念	量词结构	标签范围	含义
记忆容量	对所有输入点集、所有标签	通常实数或向量	最坏数据也能精确插值
VC 维	存在一个输入点集, 可实现所有二元标记	$\{-1, +1\}$	至少有一个点集可被打散

Memorization capacity $\leq$ VC dimension (标量二分类情形)。

6.2 深度—宽度权衡

L16 汇总的结果 (在互异输入、分段线性激活等条件下) 包括:

- 单隐层 ReLU 网络用 $\Theta(N)$ 个隐藏单元可以记忆 N 个任意样本。
- 三隐层充分条件: $d_1 d_2 \geq 4N$ 且 $d_3 \geq 4p$; 两隐层可在 $d_1 d_2 \geq 4Np$ 时记忆 N 点 p 维输出。
- 必要性示例: 单隐层若 $d_1 + 2 < N$, 或两隐层标量输出若 $2d_1 d_2 + d_2 + 2 < N$, 则存在无法记忆的 N 点数据集。
- 再增加一层时, 多类问题的节点需求可从 $\Theta(Np)$ 改善到 $\Theta(N+p)$, 体现深度对有限样本表达的节省。

记忆不等于学习失败 记忆随机标签说明模型容量很大, 也说明零训练误差不足以解释泛化; 但真实任务中, 优化算法、数据结构、显式正则化与隐式偏置可能在众多插值解中选择更简单的解。

来源: L16 pp. 3–14; Yun, Sra & Jadbabaie (2019)。

6.3 VC 维与样本复杂度

对 sign 激活的固定有向图，UML 给出

$$\text{VCdim}(H_{\{V,E,\text{sign}\}}) = O(|E| \log |E|). \quad (6.1)$$

证明轮廓：每个神经元是半空间，其 m 点增长函数至多 $(em/d)^d$ ；网络是各层与各单元函数类的复合/乘积，因此增长函数相乘，得到 $\tau_H(m) \leq (em)^{|E|}$ 。若 m 点被打散，则 $2^m \leq (em)^{|E|}$ ，从而 $m = O(|E| \log |E|)$ 。现代分段线性网络更精细的界还显式依赖深度 L 。

来源：UML §20.4；L15 p. 40 引/用 Bartlett et al. (2019)。

7. 经验风险与随机梯度下降

训练目标通常是正则化经验风险

$$\hat{R}_n(\theta) = (1/N) \sum_{i=1}^N \ell(y_i, F(x_i; \theta)) + (\lambda/2) \|\theta\|^2. \quad (7.1)$$

随机选取 i_t 或 mini-batch B_t ，构造梯度估计 g_t 。SGD 更新为

$$\theta_{t+1} = \theta_t - \eta_t g_t, \quad E[g_t | \theta_t] = \nabla \hat{R}_n(\theta_t). \quad (7.2)$$

无偏性使噪声项在条件期望下消失。对凸、 B -Lipschitz 目标，若 $\|\theta^* - \theta_0\| \leq D$ ，取 $\eta_t \approx D/(B\sqrt{t})$ ，加权平均迭代点满足 $O(DB \log t/\sqrt{t})$ 的界；若预先知道总步数 T 并用常数步长 $\eta = D/(B\sqrt{T})$ ，则

$$E[F(\bar{\theta}_T) - F(\theta^*)] \leq D^2/(2\eta T) + \eta B^2/2 = DB/\sqrt{T}. \quad (7.3)$$

推导核心来自平方距离递推：

$$E\|\theta_{t+1} - \theta^*\|^2 = E\|\theta_t - \theta^*\|^2 - 2\eta_t E\langle \nabla F(\theta_t), \theta_t - \theta^* \rangle + \eta_t^2 E\|g_t\|^2,$$

再用凸性 $F(\theta_t) - F(\theta^*) \leq \langle \nabla F(\theta_t), \theta_t - \theta^* \rangle$ 并求和望远镜消去距离项。

非凸警告 神经网络目标高度非凸，式 (7.3) 的凸收敛保证不能直接套用。一般光滑非凸分析通常只能保证某个迭代点的梯度范数较小，而不是到达全局最优；过参数化等额外结构可带来更强结论。

来源：L16 pp. 15–22；Bach §5.4；UML §20.6。

8. 初始化：为什么 He 方差是 $2/n$

零初始化会使同层单元保持完全对称；对 ReLU，某些结构下还会使激活与梯度为零。因此用独立、零均值随机权重破坏对称性。He 初始化的方差可由前向方差守恒近似推出。

设某层有 n 个独立输入 a_j ，权重 w_j 独立、 $E[w_j]=0$ ，忽略偏置：

$$z = \sum_{j=1}^n w_j a_j \Rightarrow \text{Var}(z) = n \text{Var}(w) E[a^2].$$

若 z 近似关于 0 对称，ReLU 保留约一半二阶矩： $E[\text{ReLU}(z)^2] \approx (1/2)E[z^2]$ 。希望下一层的二阶矩与当前层相当，则

$$E[a_{\text{next}}^2] \approx (1/2)n \text{Var}(w)E[a^2] \approx E[a^2] \Rightarrow \text{Var}(w) = 2/n. \quad (8.1)$$

因此 $w_j \sim N(0, 2/n)$ 或同方差的均匀分布。对线性/tanh 型激活常得到 Xavier 尺度约 $1/n$ ；更细致的版本同时考虑 fan-in 与 fan-out。

来源：L16 pp. 20–21; He et al. (2015)。

9. 反向传播：矩阵推导

9.1 前向与误差信号

采用式 (1.1) 的列向量约定。定义误差信号 $\delta^l = \partial \ell / \partial z^l$ 。输出层先由损失确定 δ^L ；例如线性输出配平方损失时 $\delta^L = a^L - y$ ，softmax 交叉熵时 $\delta^L = p - y$ 。

$$\delta^L = \nabla_{\{z^L\}} \ell. \quad (9.1)$$

9.2 递推公式

因为 $z^{l+1} = W^{l+1}a^l + b^{l+1}$ ， $a^l = \sigma(z^l)$ ，链式法则给出

$$\begin{aligned} \partial \ell / \partial a^l &= (W^{l+1})^T \delta^{l+1}, \\ \delta^l &= [(W^{l+1})^T \delta^{l+1}] \odot \sigma'(z^l), \quad l = L-1, \dots, 1. \end{aligned} \quad (9.2)$$

等价矩阵形式是 $\delta^l = \text{Diag}(\sigma'(z^l))(W^{l+1})^T \delta^{l+1}$ 。原幻灯片使用 W 的转置定义，因而公式外观不同；二者只要维度一致就是同一递推。

9.3 参数梯度

对单个元素 $z_i = \sum_j W_{ij} a^{l-1}_j + b_i$ ，有 $\partial z_i / \partial W_{ij} = a^{l-1}_j$ ，因此

$$\partial \ell / \partial W^l = \delta^l (a^{l-1})^T, \quad \partial \ell / \partial b^l = \delta^l. \quad (9.3)$$

反向传播的效率来自动态规划：前向保存每层 z^l, a^l ；反向每条边只参与常数次乘加，计算全部参数梯度的时间与一次前向计算同阶，而不是对每个参数重新跑一次链式法则。

9.4 单隐层 hinge-loss 示例

设 $z_i = w_i^T x + b_i$, $h_i = [z_i]_+$, $s = \sum_i v_i h_i + c$, $\ell(y, s) = \max(0, 1 - ys)$ 。则

$$\begin{aligned} \partial \ell / \partial s &= -y \cdot 1\{1 - ys > 0\}, \\ \partial \ell / \partial w_i &= (-y \cdot 1\{1 - ys > 0\}) v_i 1\{z_i > 0\} x. \end{aligned} \quad (9.4)$$

这正是 L16 p. 24 的四段链式乘积：输入 x 、ReLU 门、输出权重 v_i 、损失边际门。

来源：L16 pp. 23–33; UML §20.6, pp. 277–281。

10. 梯度消失与爆炸

把递推展开，可见早期层梯度包含长矩阵乘积：

$$\delta^l = D^l (W^{l+1})^T D^{l+1} (W^{l+2})^T \dots D^L \delta_{\text{out}}, \quad D^r = \text{Diag}(\sigma'(z^r)).$$

取算子范数得到

$$\|\delta^l\| \leq [\prod_{r=l}^L \|D^r\|] [\prod_{r=l+1}^L \|W^r\|] \|\delta_{\text{out}}\|. \quad (10.1)$$

若多数因子范数小于 1，乘积指数衰减；若多数大于 1，则指数增长。Sigmoid 饱和区 $\sigma' \approx 0$ 会加剧消失；ReLU 的激活侧导数为 1，但仍不能单独解决权重矩阵连乘问题。

方法	主要作用机制
He/Xavier 初始化	让前向激活与反向梯度的初始尺度近似守恒
梯度裁剪	直接限制爆炸梯度的范数
正交/规范化参数化	控制矩阵的奇异值尺度
残差连接	引入恒等路径，使 Jacobian 含 I 项
Batch/Layer Normalization	稳定中间激活尺度并改变优化几何

来源：L16 pp. 36–37。

11. 正则化与 Dropout

11.1 权重衰减

显式 ℓ_2 正则化把目标改为 $R_n(\theta) + (\lambda/2)\|\theta\|^2$, 梯度更新为

$$\theta \leftarrow \theta - \eta(\nabla \hat{R}_n(\theta) + \lambda\theta).$$

在普通 SGD 中这等价于每步先把权重乘以 $1 - \eta\lambda$, 再减去数据梯度; 在自适应优化器中, “ L_2 正则” 与解耦 weight decay 不一定等价。

11.2 Dropout 的随机计算图

训练时对激活 a 采样独立掩码 $r_i \sim \text{Bernoulli}(q)$ 。现代 “inverted dropout” 写作

$$\tilde{a} = (r \odot a)/q, \quad E[\tilde{a}|a] = a. \quad (11.1)$$

因此测试时直接使用 a , 无需再缩放。原始表述也可在训练时不除以 q 、测试时把输出权重乘 q ; 两种约定等价。被丢弃单元的局部梯度为零:

$$\partial \ell / \partial a = (r/q) \odot \partial \ell / \partial \tilde{a}.$$

Dropout 可理解为训练大量共享参数的 “瘦网络”, 抑制单元间脆弱共适应, 并近似进行模型平均。它增加梯度噪声, 保留率 q 需要与网络规模、归一化层和数据量共同调节。

来源: L16 pp. 41–42.

12. Batch Normalization 与完整梯度

12.1 前向变换

对一个 mini-batch 中某个标量特征 $x_1, \dots, x_m$, BN 定义

$$\begin{aligned} \mu_B &= (1/m) \sum_i x_i, & \sigma_B^2 &= (1/m) \sum_i (x_i - \mu_B)^2, \\ \hat{x}_i &= (x_i - \mu_B) / \sqrt{(\sigma_B^2 + \epsilon)}, & y_i &= \gamma \hat{x}_i + \beta. \end{aligned} \quad (12.1)$$

γ 与 β 允许网络恢复或改变尺度与平移。若忽略 ϵ , 取 $\gamma = \sqrt{\text{Var}[x]}$ 、 $\beta = E[x]$ 可恢复恒等映射。训练时用批统计量; 推理时通常用移动平均的总体统计量。

12.2 反向传播推导结果

令 $d_i = \partial \ell / \partial y_i$, $s = \sqrt{(\sigma_B^2 + \epsilon)}$ 。显然

$$\partial \ell / \partial \beta = \sum_i d_i, \quad \partial \ell / \partial \gamma = \sum_i d_i \hat{x}_i. \quad (12.2)$$

对输入梯度，需要同时考虑 x_i 对自身、均值与方差的影响。把链式法则展开并合并，可得到常用紧凑形式

$$\partial \ell / \partial x_i = \gamma / (m s) \cdot [m d_i - \sum_j d_j - \hat{x}_i \sum_j (d_j \hat{x}_j)]. \quad (12.3)$$

式 (12.3) 清楚显示 BN 的梯度在 batch 内耦合：一个样本的梯度取决于整批的 d_j 与 $\hat{x}_j$ 。也因此不能把均值和方差当作与输入无关的常数。

12.3 尺度不变性与解释边界

忽略 ε 且 $\alpha > 0$ 时， $\text{BN}(\alpha x) = \text{BN}(x)$ ，因此 $\text{BN}(Wx) = \text{BN}(\alpha Wx)$ 。这减弱了参数尺度对前向输出的影响，通常允许更大学习率，并对优化产生隐式调节。

历史解释需谨慎 “减少 internal covariate shift” 是 BN 原论文的动机，但并非其效果的唯一或最终解释。更稳妥的表述是：BN 重参数化并平滑/改变了优化几何，同时引入 batch 统计噪声和一定正则化效应。

来源：L16 pp. 43–47; Ioffe & Szegedy (2015)。

13. 把四条主线合在一起

问题	核心结论	不能过度推断
表达	ReLU 网络能逼近广泛函数；深度可利用组合结构节省宽度。	万能逼近不保证网络小或可训练。
记忆	较小的深网也能插值任意有限数据，甚至随机标签。	零训练误差不等于零测试误差。
优化	反向传播高效算梯度；SGD 在非凸地形中提供可行搜索。	凸 SGD 收敛率不能无条件套到深网。
泛化	范数、数据结构、算法隐式偏置比裸参数计数更关键。	容量大并不自动意味着泛化好或坏。
稳定	初始化、残差、归一化与裁剪控制信号和梯度尺度。	任何单一技巧都不是普适解释。

13.1 学习与复习检查表

- 能从核 SVM 的预测式解释“固定特征”与“学习特征”的区别。
- 能写出任意深度前馈网络的 z^l 、 a^l 递推并检查矩阵维度。
- 能从斜率变化推导一维分段仿射函数的 ReLU 表示。
- 能说明万能逼近、有限样本记忆和 VC 维分别使用什么量词。
- 能完整推导 δ^l 、 $\partial \ell / \partial W^l$ 、 $\partial \ell / \partial b^l$ 。
- 能用方差守恒推导 ReLU 的 He 初始化 $\text{Var}(w) = 2/n$ 。
- 能从矩阵乘积解释梯度消失/爆炸。
- 能写出 inverted dropout 与 BatchNorm 的前向、反向公式。
- 能区分训练误差、经验风险、总体风险与三类误差。

附录 A. 反向传播伪代码

1. 输入单个样本 (x, y) ，令 $a^0 = x$ 。
2. 前向：对 $l = 1, \dots, L$ ，计算 $z^l = W^l a^{l-1} + b^l$ ， $a^l = \sigma^l(z^l)$ 。
3. 输出误差：计算 $\delta^L = \nabla_{\{z^L\}} \ell(a^L, y)$ 。
4. 反向：对 $l = L-1, \dots, 1$ ，计算 $\delta^l = ((W^{l+1})^T \delta^{l+1}) \odot \sigma'(z^l)$ 。
5. 梯度：对每层计算 $G_W^l = \delta^l (a^{l-1})^T$ ， $G_b^l = \delta^l$ 。
6. 用 SGD/Adam 等更新参数；mini-batch 时对样本梯度求平均。

附录 B. 来源对应与延伸阅读

来源	本讲义采用的相关部分
Sra, L15	四种视角；网络结构；ReLU；非线性分离；万能逼近；深度分离；VC 维备注。
Sra, L16	有限样本记忆；SGD 实践；初始化；反向传播；梯度不稳定；Dropout；BatchNorm。
Bach, Learning Theory from First Principles	Ch. 5 SGD；Ch. 9 单隐层网络、正齐次性、Rademacher 界、变差范数、逼近与核方法关系。

来源	本讲义采用的相关部分
Shalev-Shwartz & Ben-David	Ch. 20 前馈网络、表达能力、VC 维、训练困难与反向传播。

参考文献

- Bach, F. Learning Theory from First Principles. MIT Press draft, 2025 version used here.
- Shalev-Shwartz, S. & Ben-David, S. Understanding Machine Learning: From Theory to Algorithms. Cambridge University Press, 2014.
- Cybenko, G. Approximation by superpositions of a sigmoidal function. Mathematics of Control, Signals and Systems, 1989.
- Leshno, M. et al. Multilayer feedforward networks with a nonpolynomial activation function can approximate any function. Neural Networks, 1993.
- He, K. et al. Delving Deep into Rectifiers. ICCV, 2015.
- Srivastava, N. et al. Dropout: A Simple Way to Prevent Neural Networks from Overfitting. JMLR, 2014.
- Ioffe, S. & Szegedy, C. Batch Normalization. ICML, 2015.
- Yun, C., Sra, S. & Jadbabaie, A. Small ReLU Networks Are Powerful Memorizers. NeurIPS, 2019.
- Bartlett, P. et al. Nearly-tight VC-dimension and pseudodimension bounds for piecewise linear neural networks. JMLR, 2019.